





Replikacija i konzistentnost kod Cassandra

Luka Veličković, 2101


Gossip protocol




- Mehanizam koji se koristi kod Cassandre za komunikaciju između čvorova
- Razmenjuju se informacije o stanju čvora, ali i informacije koje čvor zna o drugim čvorovima
- Svaka poruka sadrži vremensku oznaku u vidu vektorskog časovnika kako bi čvor mogao da odbaci stare informacije
- Izvršava se približno jednom u sekundi

Particionisanje podataka

- tehnika koja omogućava da se podaci podele u tzv. particije, particije se dodele čvorovima nakon čega se čvoru pristupa u slučaju pristupa određenom podatku
- kako podatke dodeljivati čvorovima?




Token ring







$\text{token}(n_1) = t_1$
 $\text{token}(n_2) = t_2$
 $\text{token}(n_3) = t_3$
...

$\text{range}(t_1, t_2] \rightarrow \{n_2, n_3, n_4\}$
 $\text{range}(t_2, t_3] \rightarrow \{n_3, n_4, n_5\}$
 $\text{range}(t_3, t_4] \rightarrow \{n_4, n_5, n_6\}$
...



- token je broj na heš prstenu. Svaki ključ podatka se kod Cassandra hešira u token i
- token definiše kom čvoru podatak pripada.
- svaki čvor je vlasnik dela prstena, odnosno svih tokena od prethodnog tokena koji pripada drugom čvoru i svog tokena



vnodes




- rešavaju problem uvođenja novih particija u sistem

Replikacija

- Cassandra koristi leaderless replikaciju, što znači da su svi čvorovi podjednaki
- Svaki čvor može da prihvati zahtev za upis podatka
- faktor replikacije
- Strategija replikacije
 - SimpleStrategy
 - NetworkTopologyStrategy
- Snitch
 - SimpleSnitch – nije rack_aware
 - PropertyFileSnitch
 - GossipingPropertyFileSnitch



Problemi kod replikacije – uvod u konzistentnost



- Čitaj svoje upise


Kvorum i nivoi konzistentnosti kod Cassandra

- Tunable consistency – na nivou upita
 - ONE
 - TWO
 - THREE
 - QUORUM
 - ALL
 - LOCAL_QUORUM
 - EACH_QUORUM
 - LOCAL_ONE
 - ANY

Nivo konzistencije	100		1000		10_000	
	Total time [s]	Latency [s]	Total time [s]	Latency [s]	Total time [s]	Latency [s]
ONE	0.05	0.55	0.58	0.58	4.1	0.41
QUORUM	0.1	1.03	1.1	1.1	8.2	0.82
ALL	0.09	0.91	0.79	0.8	8.95	0.9


- Poređenje nivoa konzistentnosti u clusteru sa tri čvora i faktorom replikacije 2

Lightweight transakcije



```
INSERT INTO users (user_id, first_name, last_name, email, created_at)
VALUES (?, 'LWT', 'User', 'lwt@example.com', toTimestamp(now()))
IF NOT EXISTS
```

Sloppy kvorum i hinted handoff



- nedostatak kvoruma – fault-tolerance, šta ako nije moguće postići kvorum sa čvorovima koji treba da skladište replike
- sloppy kvorum – upisati u neki čvor koji je dostupan, ali nije među n čvora gde se podatak obično nalazi
- hinted handoff – kada se problem sa mrežom reši, bilo koji upis u privremene čvorove će biti prosleđen do čvorova koji su trebali da čine originalni kvorum


Repair

Data / Digest Request

RF = 3
CL = QUORUM

Client

Nodes = V, W, X, Y, Z



- Hinted handoff je jedan best effort pristup, a Cassandra ne garantuje da će čvor videti sve propuštene upise. Ovakva nekonzistentnost može dovesti do gubitka podataka
 - Full repair – upoređuju sve podatke u opsegu na token prstenu koji se sinhronizuje
 - Incremental repair – upoređuje samo podatke koji su bili upisani od poslednjeg inkrementalnog repair-a
 - Read repair – „popravljanja“ podataka tokom zahteva za čitanje